

AI AGENT의 핵심 엔진

TRANSFORMER와 LLM의 이해

언어 모델의 발전사

1단계 규칙/통계	2단계 순차모델	3단계 Attention	4단계 LLM / LMM	5단계 AI Agent
Rule-based, N-gram 문법 규칙 및 단어 빈도 기반 문맥 이해 한계.	RNN, LSTM 단어를 순서대로 처리. 장기 의존성 문제, 병렬 처리 불가.	Transformer self-Attention 메커니즘 도입. 문장 전체 병렬처리 및 연과성 계산.	GPT, Claude, Gemini 대규모 코퍼스 학습 기반. 초거대 생성형 AI 및 멀티모달 확장.	LLM + Tool + Memory + Planning 자율적 목표 달성. 스스로 활용하고 다음 행동 결정. 목표 달성시까지 반복 실행

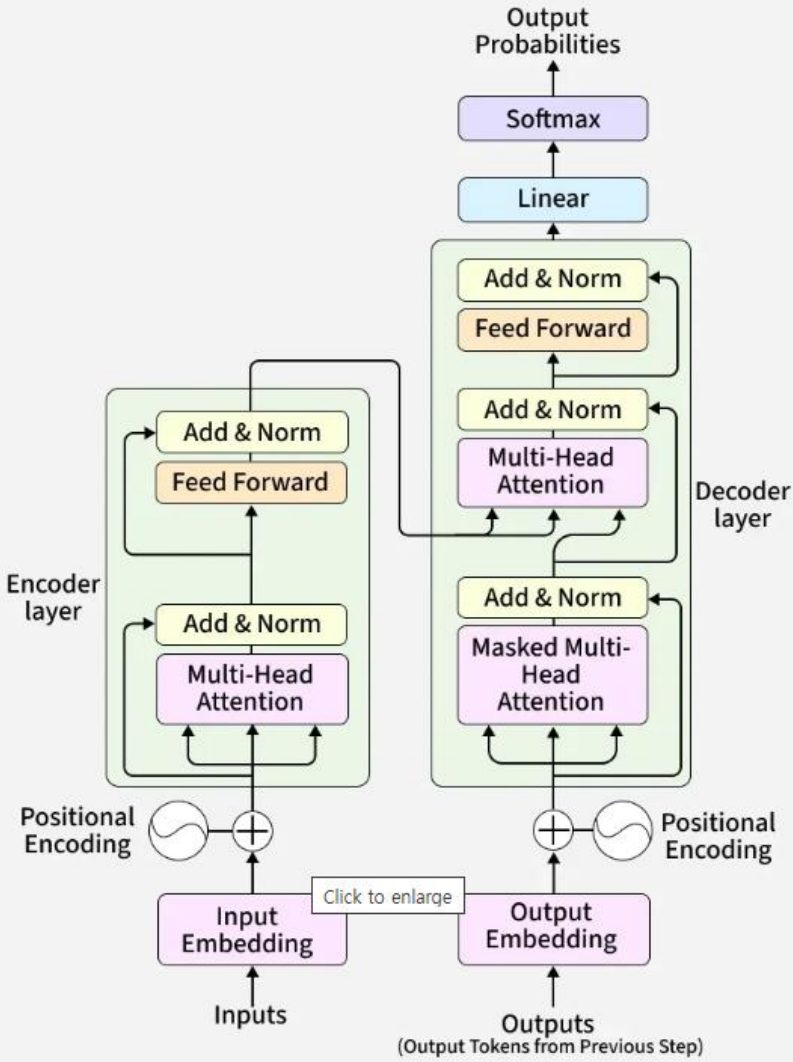
Transformer의 등장

- 기존 RNN 구조의 한계
  - RNN/LSTM
  - 순서대로 처리 → 긴 문맥에서 정보가 희석될 수 있음

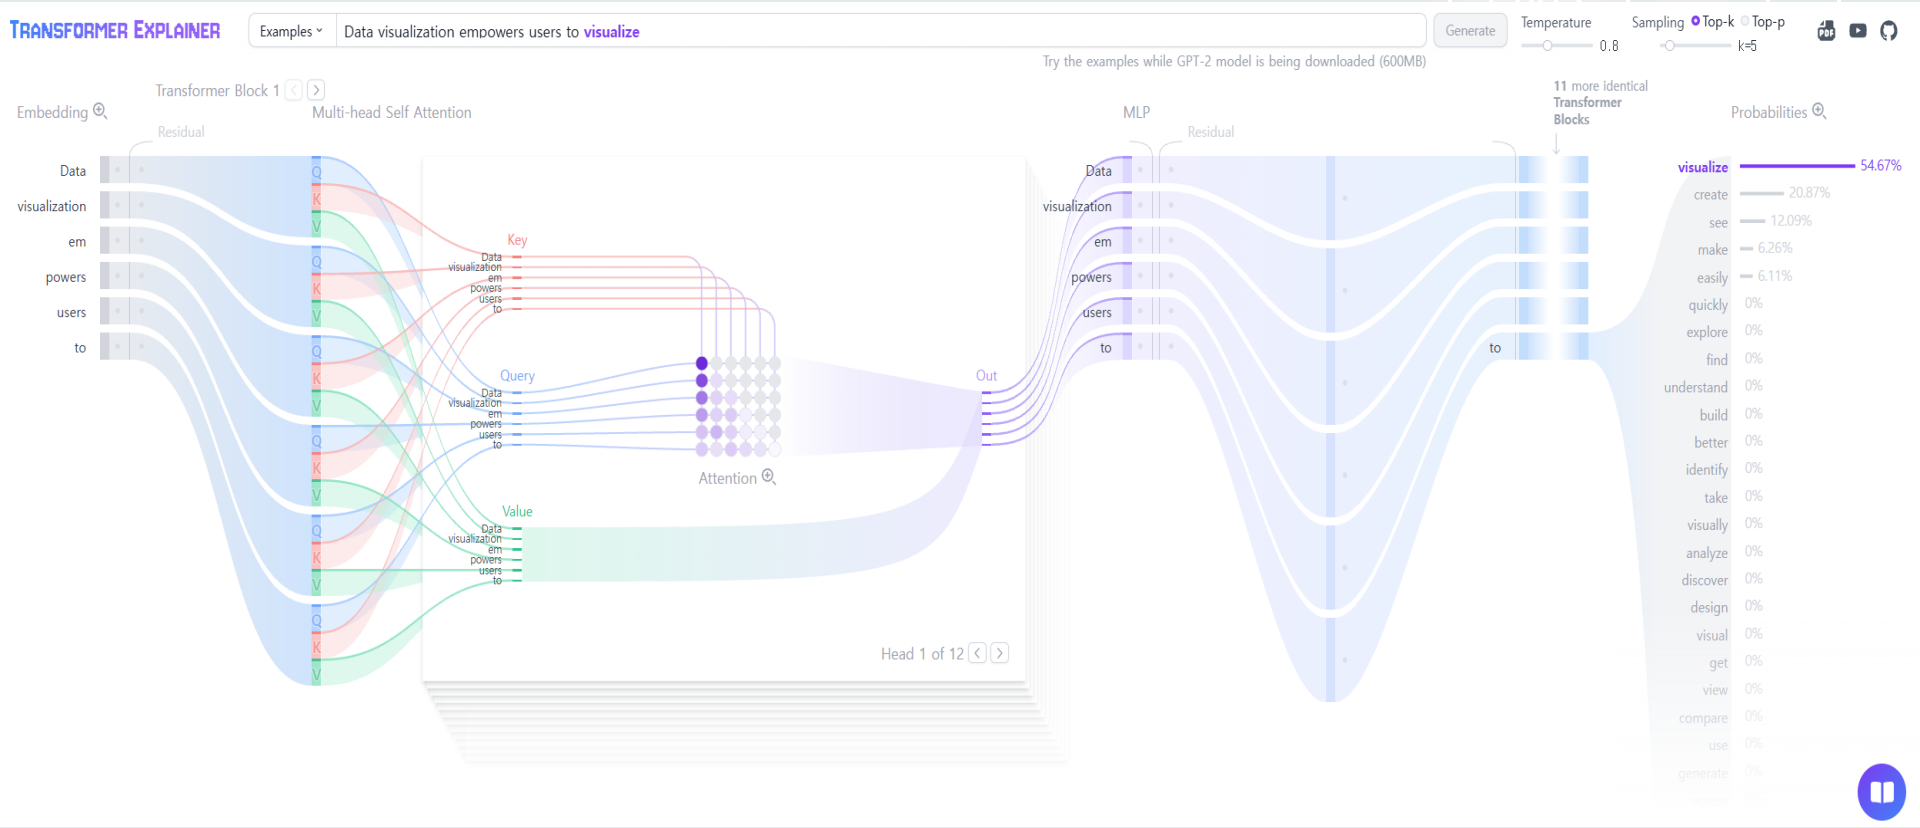
- Transformer의 혁신
  - 병렬 처리 (Parallel Processing)
    - 문장 전체를 한 번에 입력 받아 연산 속도 폭발적 증가
  - self-Attention 메커니즘
    - 문장 내 모든 단어 간의 관계 및 연관성을 가중치로 직접 계산
  - 확장성 (Scalability)
    - 모델 크기와 데이터 양을 늘릴수록 성능이 지속 상승하는 계기 마련

Transformer의 핵심구조

- Encoder
  - 입력 문장의 문맥과 의미를 이해하고 압축
  - 검색, 문장 분류, 감정 분석에 특화
- Decoder
  - 압축된 정보 및 이전 단어를 기반으로 다음 단어 예측/생성
  - GPT 시리즈, Llama (생성, 대화, 추론에 특화)



Transformer



Attention의 원리

- 문장 안에서 중요한 단어에 더 집중한다

예: '철수는 영희에게 책을 주었다. 그는 기뻐했다.'
모델은 '그'가 무엇을 가리키는지 판단할 때 주변 단어와의 관계를 계산
Attention은 각 토큰 사이의 관련도를 점수화하고, 중요한 정보에 더 큰 가중치를 부여
대표적인 형태: self-Attention → 같은 문장 안의 토큰들이 서로를 참고



LLM이 어떻게 만들어졌는가?

- LLM(Large Language Model, 대규모 언어 모델)
  - AI Agent의 핵심 두뇌 역할을 하는 기술
  - LLM은 자연어를 입력받고, 문맥을 이해한 뒤 새로운 텍스트를 생성하는 딥러닝 모델

- 오늘날의 대표적인 LLM은 Transformer 계열 아키텍처를 기반으로 발전

- 출발점: 2017년 Google 연구팀의 논문 〈Attention Is All You Need〉

LLM의 탄생과 특징

1. Decoder-Only아키텍처

현대 LLM(GPT, Llama)은 Transformer의 Decoder만을 대규모로 쌓아올려 다음 단어 예측 및 문장 생성 성능을 극대화

2. 대규모 코퍼스(Corpus) 학습

수조 개에 달하는 인터넷 상의 텍스트 데이터를 사전에 학습(Pre-training)하여 언어의 패턴과 세계 지식을 수용

3. 창발적 능력 (Emergent Abilities)

모델의 매개변수(Parameter)와 데이터가 일정 규모(보통 10B/70B 이상)를 넘어서면 가르치지 않은 수학적 추론과 코딩 능력이 스스로 발현

LLM의 진화: 텍스트를 넘어 MULTIMODAL (LMM)으로

📝 Text

문서 요약, 코드 작성,
복잡한 논리적 추론

🖼️ Vision

차트 분석,
이미지 이해,
다이어그램 해석

🎙️🎥 Audio / Video

실시간 음성 대화,
동영상 맥락 요약 및
질의응답

AI Agent 아키텍처: LLM의 핵심 역할

🧠 Brain (LLM)

목표를 이해하고, 문제를 분해하며,
다음에 무엇을 해야 할지 판단 및 계획 (Planning)

💭 Memory (기억)

단기 기억 (대화 맥락) 및
Vector DB 기반 장기 기억 (지식 연동 - RAG)

🛠️ Tools (도구 연동)

웹 검색, API 호출, Calculator,
Code Interpreter, DB 조회 등 직접 실행

⚡ Action (행동)

판단 결과를 바탕으로 외부 시스템에
명령을 내리고 목표를 자율 완수

Thanks!

- Any questions?

